

# ACH2053 – Introdução à Estatística

Aula 09c: Otimização

Valdinei Freire

valdinei.freire@usp.br

<http://www.each.usp.br/valdinei>

Escola de Artes, Ciências e Humanidades - USP

2025

O estimador:

$$\hat{\theta} = \arg \max_{\theta \in \Omega} f_n(\theta | x_1, \dots, x_n)$$

é chamado de estimador bayesiano Maximum a Posteriori (MAP).

O estimador:

$$\hat{\theta} = \arg \max_{\theta \in \Omega} f_n(x_1, \dots, x_n | \theta)$$

é chamado de máxima verossimilhança (M.L.E. - maximum likelihood estimator).

Suponha que as  $n$  variáveis aleatórias  $X_1, \dots, X_n$  formam uma amostra aleatória de uma distribuição para qual a p.d.f. (p.m.f.) é  $f(X|\theta)$ . Então:

$$L(\theta; \mathbf{x}) = f(x_1|\theta) \cdots f(x_n|\theta).$$

Para encontrar o M.L.E. usualmente considera-se a transformação  $\ell(\theta; \mathbf{x}) = \log L(\theta; \mathbf{x})$  e resolve-se a seguinte equação:

$$\nabla_{\theta} \log L(\theta) = 0.$$

**Exemplo:** Suponha que uma lâmpada regular, uma lâmpada de vida longa e uma lâmpada de vida extra-longa serão testadas. O tempo de vida de cada lâmpada é respectivamente  $X_1$ ,  $X_2$  e  $X_3$  e possuem distribuição exponencial com média  $\theta$ ,  $2\theta$  e  $3\theta$  respectivamente.

Determine o M.L.E. de  $\theta$  baseado nas observações  $X_1$ ,  $X_2$  e  $X_3$ .

# Teoria de Resposta ao Item



Considere o modelo ML2 para a Teoria de Resposta ao Item (TRI) para descrever a probabilidade de um aluno  $j$  acertar a questão  $i$ :

$$\Pr(A_{ij} = 1) = \frac{e^{a_i(\theta_j - b_i)}}{1 + e^{a_i(\theta_j - b_i)}},$$

onde  $A_{ij} \in \{0, 1\}$  é a variável aleatória que indica se o aluno  $j$  acertou ( $A_{ij} = 1$ ) ou errou ( $A_{ij} = 0$ ) a questão  $i$ ,  $\theta_j$  representa a habilidade do aluno  $j$ ,  $a_i$  representa o parâmetro de discriminação da questão  $i$ , e  $b_i$  representa o parâmetro de dificuldade da questão  $i$ .


# Exemplo com duas questões

questão	$a_1$	$b_1$	$x_1$
Q1	5	2	1
Q2	1	-2	0





# Exemplo com duas questões

questão	$a_1$	$b_1$	$x_1$
Q1	5	2	0
Q2	1	-2	1



# Exemplo com duas questões


questão	$a_1$	$b_1$	$x_1$
Q1	1	2	1
Q2	5	-2	0






# Exemplo com duas questões


questão	$a_1$	$b_1$	$x_1$
Q1	1	2	0
Q2	5	-2	1



# Maximizando Likelihood




# Maximizando log-Likelihood



# Exemplos

**Exercício 1:** encontro o ponto máximo para a função:


$$f(x) = -x^2 + x + 1$$



# Exemplos

**Exercício 2:** encontro o ponto máximo para a função:

$$f(x) = -x^4 + x^3 + 2x^2 + 5$$



## Problema de Otimização

Dada uma função  $g : \mathbb{R}^d \rightarrow \mathbb{R}$ , encontre  $\mathbf{x}^* \in \mathbb{R}^d$  tal que  $g(\mathbf{x}^*) \geq g(\mathbf{x})$  para todo  $\mathbf{x} \in \mathbb{R}$ .

## Teorema

Se  $g : \mathbb{R}^d \rightarrow \mathbb{R}$  é contínua e diferenciável, a solução  $\mathbf{x}^*$  para o problema de otimização deve atender a seguinte equação:

$$\frac{\partial g(\mathbf{x}^*)}{\partial x_i} = g'(\mathbf{x}^*) = 0 \Leftrightarrow \nabla_{\mathbf{x}} g(\mathbf{x}^*) = \mathbf{0}.$$

onde  $x_i$  representa a  $i$ -ésima dimensão da entrada  $\mathbf{x}$ .

# Método de Newton

## Teorema (Série de Taylor)

Seja  $f : \mathbb{R} \rightarrow \mathbb{R}$  uma função infinitamente diferenciável definida em um intervalo aberto  $(a - r, a + r)$ , então:

$$f(x) = \sum_{n=0}^{\infty} \frac{f^{(n)}(a)}{n!} (x - a)^n,$$

onde  $f^{(n)}(a)$  é a  $n$ -ésima derivada de  $f$  no ponto  $a$ .

## Definition (Método de Newton)

Dada uma função  $g : \mathbb{R} \rightarrow \mathbb{R}$  contínua e duas vezes diferenciáveis tal que  $g''(x^*) \neq 0$ , o método de Newton itera em valores  $x^{(t)}$  seguindo:

$$x^{(t+1)} = x^{(t)} - \frac{g'(x^{(t)})}{g''(x^{(t)})}.$$

# Método do Gradiente Ascendente

## Definition (Escalar)

Dada uma função  $g : \mathbb{R} \rightarrow \mathbb{R}$  contínua e diferenciável. O método do gradiente Ascendente itera nos valores  $x^{(t)}$  seguindo:

$$x^{(t+1)} = x^{(t)} + \beta^{(t)} g'(x).$$

## Definition (Vetorial)

Dada uma função  $g : \mathbb{R}^d \rightarrow \mathbb{R}$  contínua e diferenciável. O método do gradiente Ascendente itera nos valores  $\mathbf{x}^{(t)}$  seguindo:

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \beta^{(t)} \nabla_{\mathbf{x}} g(\mathbf{x}^{(t)}).$$

Usualmente  $\beta^{(t)} \rightarrow 0$ .



# Método do Gradiente Ascendente

1. Escolha  $x^{(0)}$  arbitrário
2. Escolha  $\beta^{(0)} > 0$  arbitrário
3. Enquanto não atende critério de parada

3.1 Faça:

$$\mathbf{x}^{(t+1)} \leftarrow \mathbf{x}^{(t)} + \beta^{(t)} \nabla_{\mathbf{x}} g(\mathbf{x}^{(t)})$$

3.2 Se:  $g(\mathbf{x}^{(t+1)}) > g(\mathbf{x}^{(t)})$

(a) Então:

$$\beta^{(t+1)} \leftarrow r\beta^{(t)}$$

(b) Caso contrário:

$$\beta^{(t+1)} \leftarrow \frac{1}{r}\beta^{(t)}$$

$$\mathbf{x}^{(t+1)} \leftarrow \mathbf{x}^{(t)}$$

**Critérios de Parada:** gradiente mínimo, quantidade de iterações máximas  
**Busca de  $\beta$ :**  $r > 1$ , mas existem vários outros métodos